

Note Scientifique

GreenChem Navigator

Équipe : 20+

31 mai 2026

1 Présentation du projet

GreenChem Navigator est une plateforme locale d'aide à la décision scientifique destinée aux chercheurs, pharmaciens et chimistes.

Le système analyse une formulation chimique ou pharmaceutique avant expérimentation afin de détecter :

- toxicité humaine ;
- impact environnemental ;
- biodégradabilité ;
- risques réglementaires ;
- problèmes liés aux solvants ;
- alternatives plus vertes.

Le principe principal est :

L'IA propose, l'expert humain valide.

2 Datasets et sources utilisées

2.1 PubChem

Utilisé pour récupérer les formules chimiques, les SMILES, les masses moléculaires et les propriétés générales des composés.

2.2 EPA CompTox

Utilisé pour les informations liées à la toxicité, l'écotoxicité, les risques chimiques et certains éléments réglementaires.

2.3 Tox21

Utilisé pour l'analyse toxicologique et l'entraînement ou la validation d'un modèle de Machine Learning simple pour prédire certains risques de toxicité.

2.4 ESOL et FreeSolv

Utilisés pour la solubilité, les propriétés de solvation, la compatibilité chimique et l'aide au choix de solvants plus adaptés.

2.5 Guides de solvants verts

Les guides GSK Solvent Sustainability Guide et CHEM21 Solvent Guide sont utilisés pour classer les solvants et proposer des alternatives plus sûres et plus vertes.

3 Méthodologie

Le système combine plusieurs approches :

- moteur de règles scientifiques ;
- calculs chimiques avec RDKit ;
- datasets publics ;
- modèle de Machine Learning ;
- scoring multi-critères ;
- validation humaine obligatoire.

Le moteur de règles permet de détecter des risques évidents.

Exemple :

```
if mercury_detected:
    trigger_alert("Heavy metal risk")
```

4 Modèle de Machine Learning

Un modèle de Machine Learning léger est intégré afin d'améliorer l'analyse de toxicité et la prédiction de certains scores.

4.1 Objectif du modèle

Le modèle ML sert à estimer :

- un score de toxicité ;
- un niveau de risque environnemental ;
- une probabilité de biodégradabilité faible ;
- un score de confiance associé aux prédictions.

4.2 Entrées du modèle

Les entrées du modèle sont des descripteurs moléculaires calculés à partir des SMILES avec RDKit :

- masse moléculaire ;
- LogP ;

- nombre de donneurs et accepteurs de liaisons hydrogène ;
- surface polaire ;
- nombre d’atomes lourds ;
- empreintes moléculaires.

4.3 Type de modèle

Pour le prototype, les modèles envisagés sont :

- Random Forest ;
- XGBoost ;
- régression logistique pour une baseline simple.

Ces modèles sont choisis car ils sont rapides, explicables et adaptés à un MVP de hackathon.

4.4 Rôle du ML dans le système

Le modèle ML ne prend pas de décision finale seul. Il fournit une prédiction qui est combinée avec :

- les règles scientifiques ;
- les données disponibles ;
- le niveau d’incertitude ;
- la validation humaine.

5 Scores analysés

Le système calcule ou estime :

- Toxicité ;
- Green Score ;
- Biodégradabilité ;
- Impact environnemental ;
- Solvant vert ;
- Risque ;
- Confiance.

Certaines métriques comme :

- E-factor ;
- Atom Economy ;
- CO₂ ;
- Yield ;

nécessitent des données supplémentaires. Si les données sont absentes, le système affiche :

`insufficient_data`

6 Déclaration de simulation

Le prototype utilise une simulation d'impact chimique et environnemental.

Cette simulation repose sur :

- des règles chimiques ;
- des scores ;
- des prédictions ML ;
- des données publiques ;
- des hypothèses déclarées.

Le système ne réalise pas de simulation quantique exacte.

7 Choix techniques justifiés

7.1 FastAPI

Choisi pour créer une API rapide, modulaire et facile à connecter avec le frontend.

7.2 RDKit

Utilisé pour le traitement des SMILES, les calculs moléculaires, les descripteurs chimiques et la comparaison de molécules.

7.3 Machine Learning

Le ML est utilisé pour compléter les règles scientifiques lorsque les données sont disponibles. Il permet d'obtenir des prédictions rapides sans entraîner de modèle lourd.

7.4 Base locale

Une base locale légère permet de stocker le cache, les scores, les alternatives et l'historique des analyses.

8 Biais identifiés

- certaines molécules possèdent peu de données ;
- les datasets peuvent être incomplets ou déséquilibrés ;
- le modèle ML peut être moins fiable sur des molécules très différentes des données d'entraînement ;
- les scores restent des estimations ;
- les réglementations varient selon les pays.

9 Limites du modèle

Le système :

- ne remplace pas un expert humain ;
- ne garantit pas le rendement réel ;
- ne réalise pas de validation expérimentale ;
- ne modélise pas entièrement le cycle de vie industriel ;
- ne doit pas être utilisé comme décision automatique.

10 Human-in-the-Loop

Toutes les recommandations nécessitent une validation humaine avant utilisation en laboratoire.

L'utilisateur peut :

- accepter ;
- modifier ;
- rejeter ;
- compléter les données manquantes.

11 Conclusion

GreenChem Navigator combine chimie verte, Machine Learning, règles scientifiques et explicabilité afin d'aider les experts à concevoir des formulations plus sûres et plus responsables.

Le projet respecte les principes suivants :

- transparence scientifique ;
- traçabilité ;
- réduction des hallucinations ;
- validation humaine ;
- aide à la décision préventive.